




Decisões de Ferramentas

Airflow

Orquestração com suporte à complexidade de dependências, agendamento e até monitoramento de mudanças no S3. Pode inclusive acompanhar a chegada do arquivo via Sensor do S3 e ainda olhar o horário para que sejam executados processos de contenção de forma reativa caso, por exemplo, o arquivo atrase para chegar. Foi pensado olhando no longo prazo, onde aumentos de complexidade e uma arquitetura maior com outras soluções deve existir, sendo um orquestrador com maior flexibilidade para suportar diversos cenários, além de, a depender do tipo de uso, ter um custo-benefício bom.

AWS EMR Cluster:

Dada a “simplicidade” do problema, com os detalhes informados, foi escolhida uma solução que é um balanço de economia de custos com processamento gerenciado. Utiliza-se de um cluster EMR para processamento sob demanda que, se dimensionado corretamente, oferece potencia de processamento à um custo acessível, sendo mantido em uptime apenas durante a execução do job de processamento dos dados e posteriormente sendo encerrado via orquestração do Airflow. Há alternativas 100% gerenciadas como o Glue, mas o custo mais alto seria justificado apenas caso houvesse utilidade latente na integração ao Glue Data Catalog.

Redshift:

Solução robusta e custo-benefício de armazenamento, com a possibilidade das queries serem feitas via Spectrum, lendo diretamente do bucket particionado por data no S3 ou via banco, assumindo a ingestão dos dados via BULK COPY. O uso do Spectrum ou não vai depender se as queries são mais analíticas e esporádicas ou em alta frequência e transacionais, onde ingerir os dados no Redshift trará maior performance.