




Decisões de Ferramentas

Kafka Connect -> AWS Kinesis

Opção de consumo visando desacoplamento, assumindo que o tópico Kafka seja disponibilizado em um cluster externo. O AWS Kinesis permite maior controle e configuração de throughput dentro do ambiente interno, permitindo evitar perdas de dados em caso de erros/retries nos consumidores ou banco, além de acelerar e facilitar o consumo dos dados a depender da solução escolhida. É necessário ter um worker Kafka Connect para trazer as mensagens do tópico Kafka para dentro do ambiente Kinesis

Lambda como consumer:

Considerando a necessidade de throughput e entrega de dados como parte principal do processo, assume-se que o processamento dos dados não é complexo. Nesse cenário ter consumidores lambdas é uma boa solução, além das capacidades de autoscaling, dado que o tempo curto de execução não é um impeditivo, usar Lambda como solução acelera o desenvolvimento e integração mantem as execuções com log organizado e throughput satisfatório para o caso, além de ter um custo-benefício muito bom. Uma alternativa, a depender do fluxo de dados e custo poderia ser o consumo direto do tópico com um cluster de contêineres Kubernetes/ECS, ao custo de perder a garantia de integridade e controle de um Kinesis interno.

Storage - DynamoDB + S3:

Considerando o cenário de dados de preço em tempo real, e assumindo que as consultas são mais focadas em acesso aos dados do que relações e cruzamentos complexos, o DynamoDB da AWS é capaz atuar como solução de armazenamento para os dados hot, com seu mecanismo de auto scaling e com alguns cuidados (ex. ids unicos para os records). Seu foco em throughput de escrita e leitura são ideias para o cenário, em especial pelo fato de que os possíveis problemas de throttling devido ao paralelismo podem ser contornados na arquitetura por termos controle sobre o fluxo de dados com o Kinesis interno. Caso seja relevante manter uma interface familiar ou se deseje padronizar os dados em base PostgreSQL por exemplo, o AuroraDB da AWS poderia ser uma alternativa, oferecendo um serviço distribuído de cluster PostgreSQL gerenciado. Finalmente, está incluído também um storage mais barato para acesso frio em buckets S3 para dados históricos, backups, debug, entre outros.