

Engenharia de Dados

1)

Cenário

A empresa quer disponibilizar um banco de dados PostgreSQL para uso em produção. Temos um time pequeno de dados e esse banco não pode ter downtime. Ele será utilizado por colaboradores em São Paulo, Nova York e Londres com alta frequência de leitura e gravação.

Tarefa

Quais aspectos e configurações devem ser levadas em consideração na disponibilização desse banco de dados? Explique-os.

Resposta:

O uso de sistemas gerenciados como o RDS da AWS facilitam vários dos pontos relevantes no cenário. Abaixo seguem considerações independentes da plataforma onde está hospedado o banco, considerando toda a configuração que poderia ser feita pelo time ao gerir o banco de dados.

Escala, Performance e Disponibilidade

Pensando em escalabilidade, há pontos de atenção como a declaração de particionamento das tabelas via cláusula **PARTITION BY**, a depender do caso de uso de cada tabela. Pode-se considerar a implementação do *Citus* também para gerar escala horizontal do banco, a se ponderar contra o aumento de complexidade de manutenção.

Para garantir a disponibilidade, o foco deve estar em garantir replicação física para que se tenha replicas prontas para aumento de escala e como pontos de failover. O parâmetro **synchronous_commit** também deve ser considerado para se balancear integridade dos dados com latência de resposta, no caso ambos parecem relevante então um ponto intermediário como **remote_write** para esse parâmetro pode ser uma opção. **PgBouncer** é um exemplo de pooler de conexão que também pode ser um pilar para distribuição de carga e automação de failover.

Finalmente, no quesito performance, podemos considerar avaliações recorrentes da **pg_stat_statements** para identificar queries ineficientes. É possível também reavaliar o parâmetro **work_mem** para o cálculo das hash tables, se atentar ao uso de índices e configuração do autovacuum para limpeza recorrente de memória.

Segurança, Monitoramento e Backup

Pensando em garantia de segurança, deve-se considerar o uso de TLS, ativando as configurações de ssl do cluster e possivelmente detalhando restrições de conexão via **pg_hba.conf**.

Dado a escala do uso e o time de dados reduzido, é de extrema importância que se tenha um bom nível de monitoramento do banco de dados, acompanhando desde estatísticas padrão como **pg_stat_activity** e **pg_stat_replication** do sistema de estatística do próprio postgresql, até registros de log de queries (a serem habilitados). O monitoramento pode ser complementado com ferramentas de monitoramento externas como o Prometheus.

É comum o uso da ferramenta **pgBackRest** para backup de snapshots do banco, a depender do tipo de hospedagem de infra utilizado, e também é importante a automatização de testes de recuperação usando esses snapshots com alguma recorrência.

2)

Cenário

Uma asset manager está expandindo sua operação de gestão de investimentos e precisa de um sistema robusto para gerenciar seus ativos, clientes, portfólios e transações. O sistema deve ser capaz de armazenar informações detalhadas sobre os ativos sob gestão, incluindo diferentes tipos de investimentos como ações, títulos de dívida (bonds) e fundos imobiliários. Além disso, deve gerenciar as contas dos clientes, os portfólios atribuídos a cada cliente, e todas as transações realizadas.

Requisitos Específicos

- Clientes: O sistema deve armazenar informações básicas de cadastro dos clientes.
- Ativos: Os ativos devem incluir as informações do ativo como nome, preço atual e moeda.
- Portfólios: Cada cliente pode ter um ou mais portfólios. Um portfólio pode incluir diversos ativos. É necessário registrar o peso ou a porcentagem de cada ativo no portfólio.
- Transações: Todas as compras e vendas de ativos devem ser registradas.
- Rendimentos: O sistema deve ser capaz de registrar os rendimentos dos ativos, como dividendos para ações e fundos imobiliários, ou pagamento de cupons para bonds

.

Tarefa

Baseando-se nos requisitos acima, crie um modelo Entidade-Relacionamento (ER) detalhado para o sistema de gestão de investimentos da asset manager. Seu modelo deve incluir todas as entidades mencionadas, seus atributos específicos e os relacionamentos entre elas. Considere as melhores práticas de normalização para evitar redundâncias e garantir a integridade dos dados.

Entregáveis

- Um diagrama do modelo ER, mostrando entidades, atributos e relacionamentos.
- Uma breve descrição de cada entidade e relacionamento no seu modelo.

Resposta:

Arquivos na pasta *dados_ex2*

3)

Cenário

Você é um analista de dados que foi encarregado de otimizar o armazenamento de dados para análises de vendas de uma grande rede de varejo. A empresa possui

um sistema de banco de dados relacional tradicional, com um modelo Entidade-Relacionamento (ER) que inclui as seguintes entidades principais: Produtos,

Vendas, Clientes, Funcionários e Lojas.

Requisitos Específicos

- **Produtos:** Armazena informações sobre os produtos vendidos, incluindo ID do Produto, Nome, Categoria, Preço Unitário e Estoque.
- **Vendas:** Registra cada venda, incluindo ID da Venda, ID do Produto, ID do Cliente, ID do Funcionário, ID da Loja, Data da Venda, Quantidade e Valor Total.
- **Clientes:** Contém dados dos clientes, como ID do Cliente, Nome, E-mail e Telefone.
- **Funcionários:** Mantém informações sobre os funcionários, incluindo ID do Funcionário, Nome, Cargo e ID da Loja em que trabalham.
- **Lojas:** Detalha as lojas da rede, com ID da Loja, Nome, Localização e Gerente.

Tarefa

A partir do modelo ER fornecido, desenvolva um Star Schema para otimizar as análises de vendas da empresa.

Entregáveis

- Um diagrama do Star Schema, identificando claramente a tabela de fatos e as dimensões.
- Uma breve descrição de cada tabelas
- Explique brevemente como você transformou o modelo ER em um Star Schema, destacando as decisões de design mais importantes.

Resposta:

Arquivos na pasta dados_ex3.

4)

Cenário

Todo dia às 03h um arquivo .txt com 50gb é disponibilizado em um bucket S3 contendo informação de todas as operações que aconteceram no dia anterior. Esses dados precisam ser tratados e disponibilizados em um data warehouse para que os indicadores estejam disponíveis às 05h para os clientes consumirem.

Tarefa

Monte a arquitetura de um pipeline que faça a ingestão, tratamento e

disponibilização desses dados de forma estruturada para consumo via queries e via dashboard.

Entregáveis

- Desenho da arquitetura contendo as ferramentas utilizadas
- Breve descrição do motivo da escolha das ferramentas

Resposta:

Arquivos na pasta dados_ex4.

5)

Cenário

Os valores de ativos listados na B3 são disponibilizados em tempo real em um tópico Kafka para consulta. Esses dados precisam estar disponíveis para a área de investimento conseguir tomar as decisões de compra ou venda de ativos.

Tarefa

Monte a arquitetura de um pipeline que faça a ingestão, tratamento e disponibilização desses dados de forma estruturada para consumo via queries e via dashboard.

Entregáveis

- Desenho da arquitetura contendo as ferramentas utilizadas
- Breve descrição do motivo da escolha das ferramentas

Resposta:

Arquivos na pasta dados_ex5.

Database Administration

1)

Explique, sucintamente, a diferença entre BEGIN/END dentro de um objeto de linguagem procedural PL/pgSQL e o BEGIN que se executa no cliente psql para execução de uma simples DML, como um update.

Resposta

Em objetos PL/pgSQL, as cláusulas BEGIN/END são utilizadas para demarcar blocos de código, como demarcar a lógica referente à uma função, conteúdo de um laço, controlando o fluxo de lógica procedural.

Já no cliente psql, as cláusulas se comportam como no padrão SQL, denotando o agrupamento de comandos pertencentes à uma única transação, permitindo se ter controle de commit e rollback das operações feitas.

2)

Assinale a alternativa que corretamente concatena as palavras 'ABC' e 'def' para formar 'ABCdef'.

- A. SELECT 'ABC' . 'def';
- B. SELECT cat('ABC', 'def') FROM pg_operator;
- C. SELECT 'ABC' + 'def' FROM dual;
- D. SELECT 'ABC' + 'def' FROM dual;
- E. SELECT 'ABC' || 'def';

Resposta:

Alternativa E.

3)

O PostgreSQL pode usar índices para acessar uma tabela, assinale duas alternativas erradas sobre índices:

- A. Um índice é criado pelo 'CREATE INDEX' e eliminado pelo 'DROP INDEX'.
- B. Quando a query usa o índice, ela pode retornar as linhas de forma muito mais rápida.
- C. Os tipos de índices são B-TREE, Hash, R-TREE e GiST.
- D. Quando se cria um índice, a query que usa aquela coluna indexada fica sempre mais rápida.
- E. Criar um índice que não esteja sendo utilizado por nenhuma query não altera de forma alguma o desempenho do banco de dados.

Resposta:

D e E.

A alternativa C pode não estar exatamente correta a depender da versão do PostgreSQL.

4)

Assinale duas afirmações corretas sobre VIEWS no PostgreSQL:

- A. Uma VIEW é criada pelo comando 'DECLARE VIEW' e eliminada pelo comando 'DROP VIEW'
- B. Uma VIEW é uma tabela virtual que não existe no disco.
- C. Uma VIEW ajuda a simplificar queries complicadas.
- D. Uma VIEW pode ser criada com o mesmo nome de uma tabela no esquema em questão.
- E. Uma VIEW só existe enquanto o processo postmaster está rodando, sendo eliminada quando o servidor para.

Resposta:

B e C

5)

Baseado na tabela EMPREGADOS abaixo, escreva uma query (suando sub query) que retorna o ID, o FIRST_NAME, o MANGER_ID e o SALARY de todos os empregados que tem salário maior que o maior salário dos empregados com MANAGER_ID igual a 100. Ordene o resultado pelo salário.

ID	FIRST_NAME	LAST_NAME	HIRE_DATE	SALARY	COMMISSION_PCT	MANAGER_ID	DEPARTMENT_ID
100	Marcelo	Goncalves	1997-04-17	20000.00	0.00	101	80
101	Carlos	Macaranduba	1997-05-18	17000.00	0.00	100	90
102	Renato	Ucraniano	1997-06-19	16000.00	0.00	100	90
300	Geraldo	Silva	2001-10-01	8300.00	0.00	205	110

Resposta:

```
SELECT ID, FIRST_NAME, MANAGER_ID, SALARY
FROM EMPREGADOS
WHERE SALARY > (
    SELECT MAX(SALARY)
    FROM EMPREGADOS
    WHERE MANAGER_ID = 100
)
ORDER BY SALARY DESC;
```

6)

Baseado na pergunta anterior, responda V para verdadeiro e F para falso na afirmações abaixo:

- A. () Um índice compostos nas colunas (manager_id, salary) é recomendado.
- B. () A query requisitada será sempre lenta, não importando como está indexada a tabela.
- C. () O PostgreSQL sempre fará a ordenação em disco, independente do índice usado.
- D. () Um índice de função (índice com expressão) deixaria a query mais rápida.
- E. () O PostgreSQL permite que se use tabelas temporárias para evitar o uso de subqueries.

Resposta

- A. V
- B. F
- C. F
- D. F
- E. V

7)

Assinale a alternativa incorreta sobre PostgreSQL:

- A. O PostgreSQL possui recurso para permitir execução de queries em paralelo.
- B. O PostgreSQL possui recurso para permitir criação de índices de forma ONLINE, sem bloquear escrita.
- C. Na criação de um banco de dados é obrigatório definir o proprietário com a palavra chave OWNER do banco.
- D. Define-se o esquema que deseja trabalhar com search_path para evitar usar o nome do esquema nas tabelas o tempo todo.
- E. Os valores do search_path podem conter esquemas separados por vírgula

Reposta:

C